

흉부 X-ray 폐렴 분류 최종 보고서

Sep 29, 2026 · @이채민

1. 개요

ImageNet 사전학습 EfficientNet-B0를 5-Fold로 학습해 검증(OOF) AUC 0.9989, 정확도 98.98%, Macro F1 0.9867을 얻었습니다. 테스트 624장은 폐렴 417장, 정상 207장으로 예측해 제출 파일을 만들었습니다.

항목	내용
대회	데이콘 · 오즈코딩 [초격차] AI 헬스케어 딥러닝 트랙 해커톤
과제	흉부 X-ray 이미지로 정상(0)과 폐렴(1)을 분류하는 이진 분류
데이터	학습 5,216장(정답 있음), 테스트 624장(정답 없음)
모델	EfficientNet-B0 전이학습, 5-Fold 앙상블 + TTA 2종
실행 환경	Google Colab GPU(CUDA), PyTorch 2.11 · torchvision 0.26
산출물	<code>submission_efficientnet_b0_384_thr0.11.csv</code>

- 대회 Public/Private 점수는 아직 받지 않아 이 보고서에 넣지 않았습니다. 받으면 4장 결과에 추가합니다.

2. 데이터 분석

학습 데이터는 폐렴이 74.3%로 정상보다 약 2.9배 많은 불균형 데이터이고, 모든 이미지가 224×224로 미리 줄여져 있습니다.

구분	정상(0)	폐렴(1)	합계	폐렴 비율
학습	1,341	3,875	5,216	74.3%
테스트	알 수 없음	알 수 없음	624	-

- 클래스 불균형:** 아무 처리 없이 학습하면 모델이 폐렴 쪽으로 쏠립니다. 손실 함수 클래스 가중치와 threshold 튜닝으로 대응했습니다(3장).

- **이미지 크기:** 무작위 300장을 확인한 결과 높이·너비가 모두 224px로 같았습니다. 원본 해상도 정보가 이미 사라진 상태입니다.
- **데이터 출처 추정:** 학습셋 장수(정상 1,341·폐렴 3,875)가 공개 데이터셋 Kermany et al.(2018) 소아 흉부 X-ray의 학습셋과 정확히 같습니다. 같은 출처라면 테스트셋은 정상 234장·폐렴 390장(폐렴 62.5%)으로 학습셋보다 정상 비율이 높을 가능성이 큼니다.

3. 방법론

사전학습 CNN을 흉부 X-ray에 맞게 미세조정하고, 불균형은 손실 가중치와 threshold 튜닝으로, 예측 안정성은 폴드 앙상블과 TTA로 확보했습니다.

1. **전처리:** CLAHE(clipLimit 2.0, 8×8 타일)로 폐 음영 대비를 높이고, 흑백 이미지를 3채널로 복제해 ImageNet 가중치를 그대로 씁니다.
2. **증강:** 회전 $\pm 10^\circ$, 이동 $\pm 6\%$, 확대·축소 0.9~1.1배, 밝기·대비 $\pm 15\%$ 만 적용했습니다. 좌우 반전은 심장 위치가 바뀌어 실제 영상에 없는 형태가 되므로 제외했습니다.
3. **모델:** torchvision EfficientNet-B0(파라미터 약 5.3M)의 마지막 층을 2-class 출력으로 바꾸고 백본 전체를 미세조정했습니다.
4. **학습:** Stratified 5-Fold로 폴드마다 학습 4,172~4,173장, 검증 1,043~1,044장을 나눴습니다. 폴드 별로 검증 AUC가 가장 높은 가중치를 저장했습니다.
5. **Threshold 튜닝:** 5개 폴드의 OOF 예측 확률 전체(5,216장)에서 Macro F1이 최대인 기준값을 0.05~0.95 범위, 0.01 간격으로 찾았습니다.
6. **추론:** 폴드 모델 5개 × TTA 2종(원본, 1.1배 확대 후 중앙 자르기) = 예측 10개의 확률을 평균한 뒤 threshold를 적용했습니다.


학습 설정	값
입력 크기	384 × 384
배치 크기	32
손실 함수	CrossEntropy + 클래스 가중치(정상 1.945, 폐렴 0.673) + Label smoothing 0.05
Optimizer	AdamW (lr 3e-4, weight decay 1e-4)
Scheduler	1 epoch warmup 후 Cosine decay
최대 Epoch / Early stopping	15 / 검증 AUC 기준 patience 4
기타	AMP(mixed precision), gradient clipping 2.0, seed 42

4. 실험 결과

5개 폴드 모두 검증 AUC 0.998 이상으로 고르게 수렴했고, threshold를 0.5에서 0.11로 낮추자 OOF Macro F1이 0.9780에서 0.9867로 올랐습니다.

4.1 폴드별 학습 결과


폴드	최고 검증 AUC	최고 AUC epoch	학습 종료 epoch
Fold 0	0.9985	5	9
Fold 1	0.9992	6	10
Fold 2	0.9994	10	14
Fold 3	0.9997	9	13
Fold 4	0.9994	4	8



- 모든 폴드가 1~2 epoch 만에 AUC 0.995를 넘었고, 이후에는 검증 손실이 0.07~0.18 사이에서 오르내렸습니다. 대부분 early stopping으로 15 epoch 전에 끝났습니다.
- epoch당 약 80초가 걸렸습니다. 첫 epoch만 1,260초가 걸린 것은 Google Drive에서 이미지를 처음 읽어올 때의 지연 때문입니다.

4.2 OOF 성능 (학습 5,216장, threshold 0.11)


클래스	Precision	Recall	F1	장수
정상	0.9835	0.9769	0.9802	1,341
폐렴	0.9920	0.9943	0.9932	3,875
Macro 평균	0.9878	0.9856	0.9867	5,216



- 전체 정확도 98.98%, AUC 0.9989입니다. 5,216장 중 틀린 것은 53장(정상을 폐렴으로 31장, 폐렴을 정상으로 22장)입니다.
- 오른쪽 그래프처럼 threshold 0.1~0.8 구간에서는 F1이 0.96 이상으로 거의 평평합니다. 0.11이라는 값 자체보다 이 넓은 안정 구간이 더 중요합니다.

4.3 테스트 예측


예측 10개(모델 5 × TTA 2)의 평균 확률에 threshold 0.11을 적용해 폐렴 417장(66.8%), 정상 207장(33.2%)으로 예측했습니다.



- 확률이 0 근처와 0.9 근처로 크게 나뉘지만, 0.1~0.8 사이에도 약 100장이 넓게 퍼져 있습니다. OOF에서는 이 중간 구간이 거의 비어 있었으므로, 테스트셋이 학습셋과 다른 분포라는 신호입니다.
- 제출 점수: 아직 받지 않았습니다. 받으면 이 자리에 Public/Private 점수를 추가합니다.

5. 모델 해석 (Grad-CAM)

8장 중 폐 실질에 활성화가 집중된 것은 일부뿐이고, 여러 장에서 어깨, 방향 표시 글자("R"), 이미지 가장자리에 활성화가 몰렸습니다. 모델이 병변 외의 단서도 함께 쓰고 있을 가능성이 있습니다.



샘플	예측 확률 P(폐렴)	활성화 위치
정상 1~4	0.00~0.01	이미지 모서리, 검은 여백, 횡격막 아래
폐렴 1	0.93	왼쪽 어깨·방향 표시 부근, 왼쪽 아래 폐
폐렴 2	0.92	양쪽 폐 실질 (의도한 형태)
폐렴 3	0.94	양쪽 어깨와 쇄골 띠
폐렴 4	0.19	왼쪽 위 방향 표시 부근, 오른쪽 아래 폐

- **정상 샘플 해석 주의:** 예측 확률이 0에 가까우면 폐렴 신호 자체가 거의 없어서, 0~1로 정규화한 히트맵은 작은 잡음을 크게 보여줍니다. 정상 샘플의 모서리 활성화는 과대 해석하지 않는 것이 맞습니다.
- **폐렴 샘플은 주의가 필요합니다:** 확률이 높은 3장 중 2장이 폐보다 어깨나 방향 표시 부근을 강하게 봤습니다. 이런 shortcut learning은 촬영 기관이나 장비가 바뀌면 성능이 떨어지는 원인이 됩니다.
- **폐렴 4:** 확률 0.19로 threshold 0.5에서는 놓쳤을 사례입니다. 0.11 기준이 이런 사례를 폐렴으로 잡아냈습니다.
- 8장은 적은 표본이므로, 결론을 내리려면 오분류 53장 전체를 같은 방식으로 확인해야 합니다.

6. 고찰 및 한계

OOF 성능(정확도 98.98%)은 테스트 성능을 과대평가했을 가능성이 높습니다. 가장 큰 이유는 학습·테스트 간 분포 차이와 환자 단위로 나누지 못한 검증입니다.

1. **Threshold 0.11은 테스트에서 폐렴을 과잉 예측할 수 있습니다.** 이 값은 폐렴 74.3%인 학습 분포에서 찾은 것입니다. 테스트가 원본 데이터셋 구성(정상 234 · 폐렴 390)을 따른다면, 폐렴 417장 예측은 최소 27장의 정상을 폐렴으로 분류했다는 뜻입니다. 이 경우 정확도는 최대 95.7%(597/624)를 넘을 수 없습니다.
2. **검증이 낙관적일 수 있습니다.** 원본 데이터에는 한 환자의 영상이 여러 장 있습니다. 대회 파일명이 바뀌어 환자 단위로 폴드를 나눌 수 없었으므로, 같은 환자가 학습과 검증에 동시에 들어갔을 수 있습니다.
3. **확률값이 보정되어 있지 않습니다.** 정상 클래스에 약 2.9배 가중치를 주고 label smoothing을 쓴 탓에 확률이 정상 쪽으로 밀렸고, 그래서 최적 threshold가 0.11까지 내려갔습니다. 0.11을 "폐렴 확률 11%"로 읽으면 안 됩니다.
4. **입력 해상도 이득이 없습니다.** 원본이 224×224라서 384로 키워도 새 정보가 없고, 연산량만 약 2.9배($384^2 / 224^2$) 늘었습니다.
5. **Shortcut learning 가능성이 있습니다.** 5장에서 본 것처럼 일부 폐렴 예측이 어깨나 방향 표시 부근에 의존했습니다.
6. **임상적 관점:** Macro F1은 두 종류의 오류를 같은 무게로 봅니다. 실제 선별 검사라면 폐렴을 놓치는 오류(OOF 22장)가 더 치명적이므로, 목적에 따라 threshold 기준을 달리 정해야 합니다.
- 참고: 학습 중 출력된 `_MultiProcessingDataLoaderIter.__del__` 경고는 Python 3.13에서 DataLoader 작업 프로세스를 정리할 때 생기는 메시지로, 학습 결과에는 영향이 없습니다.

7. 향후 개선 방향

가장 먼저 할 일은 저장된 테스트 확률로 threshold만 바꿔 다시 제출해 보는 것입니다. 재학습 없이 바로 확인할 수 있습니다.

우선순 위	할 일	기대 효과
1	test_prob_efficientnet_b0.csv 로 threshold 0.3 · 0.5 · 0.7 제출 비교	분포 차이에 따른 폐렴 과잉 예측 확인 및 교정
2	입력 크기를 224~256으로 낮추고 남은 연산으로 백본 추가(DenseNet121, ConvNeXt-T)	같은 시간에 모델 앙상블 가능
3	이미지 가장자리 잘라내기 또는 폐 영역 분할(U-Net) 후 ROI만 분류	어깨·방향 표시 등 shortcut 억제
4	클래스 가중치 대신 WeightedRandomSampler 또는 Focal Loss 비교	확률 보정 개선, threshold 해석 용이
5	오분류 53장 전체에 Grad-CAM 적용	오류 유형 파악, 근거 영역 정량 점검
6	흉부 X-ray로 사전학습된 가중치(TorchXRayVision 등) 사용	도메인에 맞는 특징으로 일반화 향상

- 외부에서 같은 테스트 원본 이미지를 구해 학습에 섞는 것은 대회 규칙 위반 소지가 있어 사용하지 않습니다.

8. 참고문헌

1. Kermany, D. S., et al. (2018). Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning. *Cell*, 172(5), 1122–1131.
2. Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *ICML 2019*.
3. Rajpurkar, P., et al. (2017). CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning. arXiv:1711.05225.
4. Selvaraju, R. R., et al. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. *ICCV 2017*.
5. Zech, J. R., et al. (2018). Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs. *PLOS Medicine*, 15(11).